frag.extract

Beginner Practical by

Florian Rauls, Simon Gimmini, Tobias Neuschäfer
at Heidelberg University

Überblick

- Aufgabe
- Projektzusammenfassung
- Ablauf
- Chrome Extension
- Extraction Model
- Ausblick
- Lehre

Aufgabe

- Entwicklung von
  - Google Chrome Erweiterung zum Erstellen von Code Fragmenten aus einem Fragen Thread und Speichern von diesen in einer Datenbank (über Frag Edit VSC Erweiterung)
  - Neuronalem Netz zum Determinieren des besten Codes zu bestimmter Intention

Projektzusammenfassung

- Lines of Code:

Teil	Zeilen
Chrome Extension Skripte	537 (158 comments)
Chrome Extension HTML	125
Extraction Model	81 (71 comments)
Total inkl. ReadMe, JSON (Model)	913

- Pair Programming Sessions: eine (zur Installation des Native Messaging Hosts), sonst oft "soft" Pair Programming über Discord, Telegram
- >13 integration tests

Ablauf

- Erste Struktur von PopUp entwickelt
- Kommunikation zwischen Chrome und VSC aufgebaut
- Button zum manuellen Auswählen von Fragmenten eingebaut
- Design überarbeitet
- Funktionalität/Logik der Fragmente in Design umgesetzt
- Nutzung des Models zum Voraussagen von Fragmenten
- Finales Testen der Funktionen

Chrome Extension - Design

Designfragen:

- Wie breit darf das Popup sein?
- Wie werden die Komponenten dargestellt?
  - Chips ("Tags"), Auswahldialoge, andere Schriftarten
- Wie kann man im Design Funktionale Anforderungen Umsetzen

Entscheidungen:

- Nicht breiter als der "Werberand"
- Tags als Tags
- Sprache als Auswahl
- Code in monospace
- Label und Code als verpflichtende Felder um leere und nicht gelabelte Fragmente zu verhindern
- Tags können durch einfaches "x-en" entfernt werden
- Konträre Icons statt langer Texte

Chrome Extension - Design

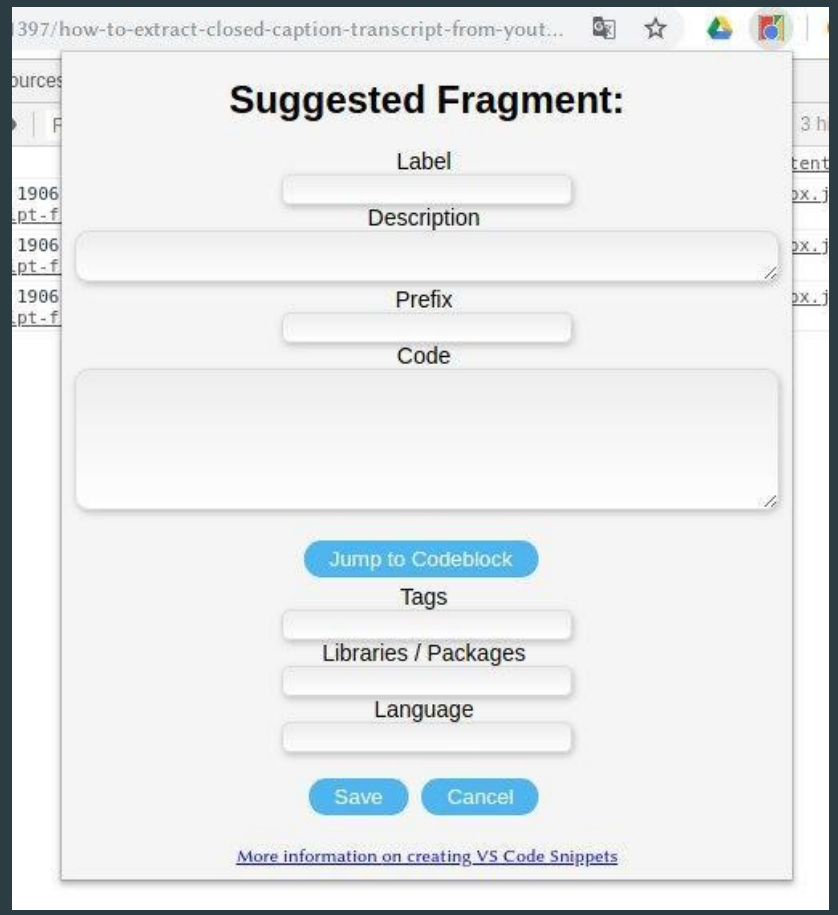

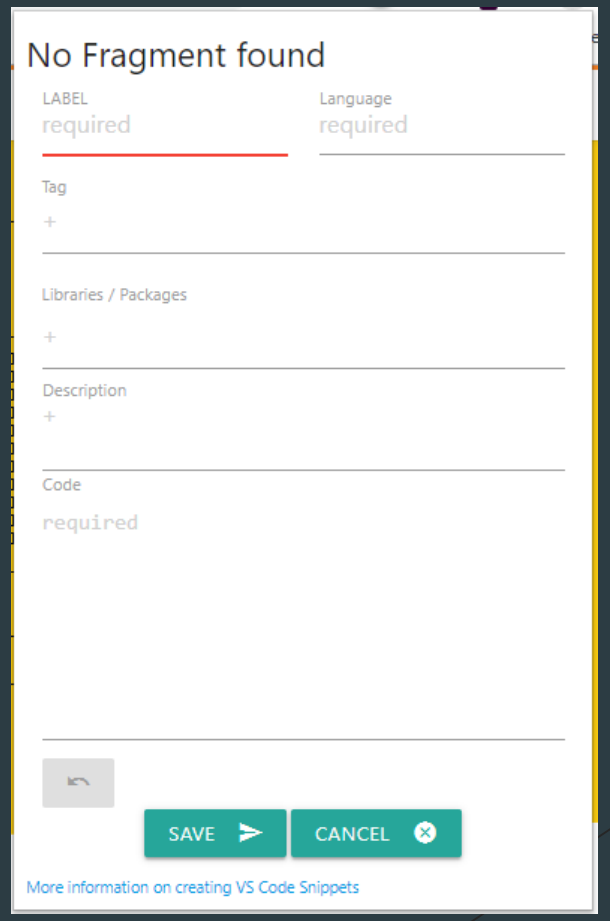

Chrome Extension - Funktionalität

- Inhalt des Popups wird automatisch gespeichert und bei erneutem Öffnen geladen
- Alle Fragment Attribute werden entweder automatisch befüllt oder es werden Vorschläge gemacht
- Man kann zum ausgewählten Codeblock auf der Seite scrollen und jeden Codeblock manuell auswählen

- Native Messaging Protocol zur Übertragung der Fragmente
- NM-Host wird durch VSC-Erweiterung installiert
- Host empfängt Fragmente aus Google Chrome und verarbeitet diese für die Datenbank

Home
PUBLIC
Stack Overflow
Tags
Users
Jobs
TEAMS What's this?
Q&A for Work

1 2 next

4617

Short & Snazzy:

```
+ new Date()
```

A unary operator like `plus` triggers the `valueOf` method in the `Date` object and it returns the timestamp (without any alteration).

Details:

On almost all current browsers you can use `Date.now()` to get the UTC timestamp in **milliseconds**; a notable exception to this is IE8 and earlier (see compatibility table).

You can easily make a shim for this, though:

```
if (!Date.now) {
    Date.now = function() { return new Date().getTime(); }
}
```

To get the timestamp in **seconds**, you can use:

```
Math.floor(Date.now() / 1000)
```

Or alternatively you could use:

```
Date.now() / 1000 | 0
```

Which should be slightly faster, but also less readable (also see this answer).

I would recommend using `Date.now()` (with compatibility shim). It's slightly better because it's shorter & doesn't create a new `Date` object. However, if you don't want a shim & maximum compatibility, you could use the "old" method to get the timestamp in **milliseconds**:

Suggested Fragment

LABEL: some label
Language: javascript
Tag: date, unix-timestamp
Libraries / Packages: datetime, timestamp
Description: How do you get a timestamp in JavaScript?
Code:

```
Date.now() / 1000 | 0
```

SAVE CANCEL

More information on creating VS Code Snippets

see more linked questions...

Related

7647 How do JavaScript closures work?
2234 How can I convert a string to boolean in JavaScript?
2341 Encode URL in JavaScript?
2895 How to append something to an array?
7224 What does "use strict" do in JavaScript, and what is the reasoning behind it?
2050 How do I get the current date in JavaScript?
7432 How to check whether a string contains a

Extraction Model

Grundidee:

- Datensatz (CoNaLa-Corpus) mit folgendem Inhalt:
  - "Intent" in natürlicher Sprache
  - Zugehöriges Code Fragment
- Datensatz als Trainingsgrundlage für ein Neuronales Netz
- NN unterstützt den User bei der Auswahl der Fragmente

Probleme:

- Ein in bspw. Python oder R trainiertes Model nicht nur in JavaScript, sondern gleich in einer Chrome Extension einbinden
- Training in JavaScript theoretisch möglich, aber wirft Probleme im Bereich Performanz auf
- Preprocessing muss in JavaScript reproduzierbar sein, um Daten zur Bewertung einzuspeisen
- Komplexes Problem erfordert ein komplexes Model --> Trotzdem muss die Auswertung am Ende performant sein

Export nach JavaScript

Theorie:

- Training des Neuronalen Netzes in Python (bspw. mit Keras)
- Abspeichern des Models in .h5-Format
- Konvertieren in TensorFlow.js-Format
- Laden des Models in der Extension
- Predictions in der Extension möglich

Export nach JavaScript

Auf TensorFlow.js übertragbar

Praxis:

https://me.me/i/if-javascript-was-a-car-hmmm-934b5ba923ae40abbad65a53f5e0f02e

Export nach Javascript

Probleme -> Lösungen:

- Laden des Models erweist sich als sehr trickreich, da dies ausschließlich über eine URL möglich ist -> Hosting per GitHub-Pages
- TensorFlow.js lange nicht so ausgereift wie Keras/TensorFlow (Layer fehlen) -> Langes herumprobieren mit verschiedenen Layern und Stöbern in der Dokumentation
- Laden von Objekten erzeugt Promises, welche abgewartet werden müssen -> Nutzen von async-Funktionen
- Preprocessing -> Siehe nächster Abschnitt

Preprocessing

Beispielhafter Ablauf:

- Intent: "How to loop in Python?"
- Code: "for i in range(0, 10): print("Do stuff")"

Zusammenfügen + lower() + Sonderzeichen entfernen

- -> "how to loop in python **border_symbol** for i in range 0 10 print do stuff"

Tokenization + Padding auf feste Länge

- [2, 3, 4, 6, 12, 1, 44, 77, 32, 98, 555, 0, 0, 0, 0, 0,0]

Einspeisen + Vorhersage des Models

75,32156 %iges Match

Preprocessing

Problem:

- Daten müssen in derselben Form zum Zeitpunkt der Prediction dem Neuronalen Netz vorliegen, wie sie beim Training vorlagen
  -> Tokenization muss reproduzierbar sein

Lösung:

- Beim Erstellen der Tokens in Python wird ein Dictionary erstellt, welche Worte zu ihrem Index mappt
  -> Abspeichern im JSON-Format
- Laden beim Start der Extension und algorithmisch den Vorgang der Tokenization nachvollziehen (inklusive Padding etc.)

Performanz

Problem:

- Teilweise über 30 Codeblöcke auf einer Stackoverflow Seite vorhanden
- Auswertung erfordert viel Zeit, wodurch die Erfahrung des Endnutzers verschlechtert wird

Lösung:

- Ausschließlich Betrachtung einer festen Anzahl an Codeblöcken (zurzeit die obersten 5), welche in Betracht gezogen werden
- Dadurch entsteht einheitliche Nutzererfahrung, egal welche Seite er öffnet
- Zudem besteht die Annahme, dass wenn sich die gesuchte Antwort nicht bereits in den 5 Antworten mit den meisten Votes wiederfindet, dass das eigene Problem zu speziell ist bzw nicht auf den Titel der Page passt und ohnehin manuell gesucht werden muss

Ausblick

- Parametrisierungsalgorithmus von Frag Edit funktioniert gut in Tests mit Fragmenten, die aus Stackoverflow erstellt wurden
  -> zukünftig möglicherweise automatische Anwendung des Algorithmus auf neue Fragmente, die von der Chrome Erweiterung kommen
- Portierung der Chrome Erweiterung für Mozilla Firefox ist möglich
- Aufgrund der gegebenen Daten (geringe Qualität) ist das Model noch unzuverlässig, auch wenn es immer wieder gute Ergebnisse liefert
  -> qualitativ hochwertigere Daten würden die Zuverlässigkeit steigern
- Infrastruktur bereits gegeben
  -> es könnte bspw. ein Crawler eingesetzt werden, der mehr Daten generiert
- Workarounds im Bereich TensorFlow.js könnten Zugriff auf ein hochwertigeres Netz bieten
  -> Würde die Zuverlässigkeit ebenfalls steigern

Lehre

- Besser in neue Sprache einarbeiten anstatt nur von Beispielen ausgehend nach Vermutungen zu coden
- Probleme nicht stur von nur einer Seite aus angehen
  - Nutzung einer festen Bibliothek für Tokenization in Python ist nicht reproduzierbar in JavaScript
  - Schreiben eines einfachen, eigenen Ansatzes wäre effektiver und zeitsparender gewesen
- Nicht auf die Dokumentation von Bibliotheken verlassen
  - Materialize nicht aktuell und lückenhaft
  - TensorFlow.js nicht sauber strukturiert/vollständig
  - Googles Native Messaging Beispiel nicht funktionsfähig

Referenzen

- Github Repository
- Materialize Library
- TensorFlow.JS